CIFAR-10 이미지 분류에서 CNN과 ResNet 구조 최적화 및 성능 비교

202502515 박원일, 202400591 이승재, 202401742 하정아

1. 서론

컴퓨터 비전 분야에서 합성곱 신경망(Convolutional Neural Network, CNN)은 이미지 인식 및 객체 분류 과제에서 핵심적인 모델로 자리 잡았다. CNN은 기존의 완전 연결 신경망이 1차원 벡터 변환 과정에서 이미지의 형상 정보를 소실하는 것과 달리 2차원 위상 정보를 보존하며 학습한다. 이는 Convolution 연산을 통해 지역적 특징을 감지하고, Pooling을 통해 위치 불변성을 확보하는 CNN 특유의 설계에서 기인한다[1]. 이러한 구조적 이점 덕분에 CNN은 단순한 패턴 매칭을 넘어 복잡한 시각 정보를 계층적으로 학습할 수 있으며, 최근 국내 산업계에서도 이러한 기술적 우위를 바탕으로 스마트 팩토리의 미세 결함 탐지나 지능형 CCTV 기반의 이상 행동 분석 등 고도화된 영상 분석 시스템에 적극적으로 도입되고 있다[2].

최근 데이터의 규모가 커지고 분류해야 할 클래스가 세분화됨에 따라, 더 높은 차원의 특징을 학습하기 위해 신경망의 깊이를 늘리는 것이 필수적 요소가 되었다. 이에 따라 Layer를 더 깊게 쌓은 Deep CNN이 연구되었으나, 네트워크가 일정 깊이 이상으로 깊어질 때 성능이 향상될 것이라는 기대와 달리 두 가지 치명적인 문제가 발생하였다. 첫번째는 기울기 소실문제이다. 신경망의 가중치를 업데이트하기 위해서는 출력층의 오차를 입력층 방향으로 전달하는 Backpropagation 과정이 필수적이다. 그러나 이 과정에서 연쇄 법칙에 의해 다수의 미분값들이 연속적으로 곱해지게 되는데, 만약 이 값들이 1보다 작다면 층을 거듭할수록 기울기는 기하급수적으로 감소하게 된다. 결국 입력층에 도달했을 때는 유의미한 기울기 정보가 남지 않아 가중치 학습이 사실상 중단되는 현상을 초래한다. 두번째는 성능 저하(Degradation) 현상이다. 이론적으로는 신경망의 층이 깊어질수록 모델의 표현력이 증가하여 더 복잡한 특징을 학습할 수 있어야 한다. 그러나 실제 실험에서는 네트워크 깊이가 특정 수준을 넘어가면, Overfitting이 발생하지 않았음에도 불구하고 오히려 학습 오차와 테스트 오차가 얕은 모델보다 높게 나타나는 역설적인 현상이 관찰된다. 이는 깊은 모델이 얕은 모델의 해를 포함할 수 있는 충분한 용량을 가지고 있음에도 불구하고, 현재의 학습 방법으로는 이를 최적화하는 난이도가 급격히 상승함을 보여준다. 결과적으로 이러한 성능 저하 현상은 단순한 층의 Stacking만으로는 성능 향상을 보장할 수 없다는 구조적 한계를 시사한다[3].

He et al.은 앞서 제기된 최적화 난제를 근본적으로 해결하기 위해 잔차 학습(Residual Learning) 프레임워크인 ResNet을 제안하였다. 이 구조의 핵심은 입력 데이터를 별도의 변환 없이 출력에 바로 더해주는 Skip Connection에 있다. 이는 기존 네트워크가 입력(x)

을 타깃(H(x))으로 직접 Mapping하기 위해 복잡한 함수 자체를 학습하려 했던 것과 달리, 학습의 목표를 잔차(F(x) = H(x) - x)를 최소화하는 문제로 재정의한 것이다.

만약 최적의 함수가 항등 함수라면, 복잡한 비선형 레이어들이 복잡한 연산을 수행하는 것보다 잔차(F(x))를 0으로 수렴시키는 것이 수학적으로 훨씬 용이하다. 더 나아가, 이러한 구조적 변화는 역전파 과정에서도 결정적인 이점을 제공한다. 또한, 스킵 연결은 역전파 시 미분값이 1인 지름길을 형성하여, 상위 층의 오차 신호가 하위 층으로 감쇄 없이 직접 전달되는 '기울기 Highway' 역할을 수행한다[3]. 이러한 원리를 통해 100층 이상의 초심층 네트워크에서도 정보 손실 없는 학습이 가능해졌으며, 국내 선행 연구에서도 고해상도 의료 영상과 같은 복잡한 데이터셋 환경에서 ResNet이 기존 모델 대비 월등히 안정적인 수렴 성능을 보임을 실증적으로 입증하고 있다[4].

CNN 아키텍처의 발전사는 구조적 한계를 극복하고 연산 효율성을 최적화하기 위한 일련의 연구 흐름으로 요약된다. 초기 AlexNet 이후 등장한 VGGNet은 3 x 3 소형 필터를 깊게 쌓아 올리는 방식을 통해 모델의 깊이가 성능에 미치는 긍정적 영향을 증명했으나, 그 대가로 막대한 연산량을 감수해야 했다. 이러한 비효율성을 해결하기 위해 도입된 것이 GoogLeNet(Inception)이다. 이 모델은 단일 필터 대신 다양한 크기의 필터를 병렬로 연결하는 Inception 모듈을 도입하여, 깊이를 유지하면서도 연산 비용을 획기적으로 절감하는 데 성공했다. 이후 ResNet은 깊이에 따른 학습 한계를 극복하며, 딥러닝 아키텍처 역사의 중요한 분기점이 되었다. 최근에는 ResNet의 잔차 연결 구조를 기반으로 하여 채널 간의 중요도를 선별하여 정보의 밀도를 높이는 Attention 메커니즘을 결합하거나, 한정된 자원을 가진 모바일 환경에서도 원활히 구동되도록 구조를 경량화하여 효율성을 극대화하는 등, 국내외 학계와 산업계에서는 효율성과 정확도를 동시에 확보하기 위한 다양한 파생 연구가 활발히 전개되고 있다[4].

본 연구는 CNN의 깊이가 증가함에 따라 발생하는 구조적 한계를 실제 데이터셋을 통해 면밀히 관찰하고, ResNet이 이러한 문제를 어떻게 개선하는지 실험적으로 검증하는 것을 주된 목적으로 한다. 이를 위한 실험 데이터셋으로는 이미지 분류 분야의 표준 벤치마크인 CIFAR-10을 활용하고자 한다. CIFAR-10 데이터셋은 32x32 픽셀 해상도의 컬러(RGB) 이미지 총 60,000장으로 구성되어 있으며, 비행기, 자동차, 새 등 서로 겹치지 않는 상호 배타적인 10개의 클래스를 포함한다. 전체 데이터는 모델 학습을 위한 50,000장의 Training Batch와 최종 성능 평가를 위한 10,000장의 Test Batch로 나누어 활용된다[5]. 결론적으로 본 연구는 CIFAR-10 데이터셋을 활용하여 일반적인 CNN 모델과 ResNet 모델을 구축하여 학습 과정을 비교함으로써, 심층 신경망 설계에 있어 잔차 학습이 갖는 효용성을 재확인하고, 최적의 모델 설계를 위한 기초 자료를 제시하는 것을 목적으로 한다.

2. 본론

2.1 CNN

이번 프로젝트에선 CNN과 ResNet의 성능 비교가 주된 목적이므로,

먼저 CNN의 구조화 후 하이퍼파라미터 조절로 최적의 test 정확도를 찾으려고 하였다.

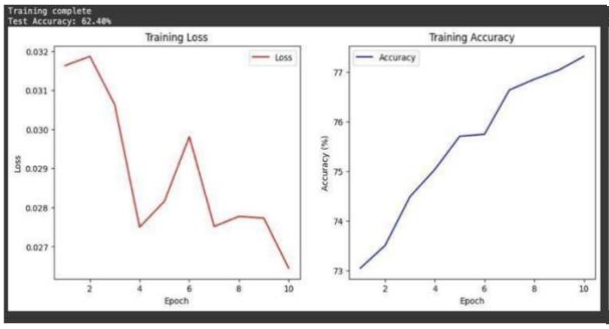

최초 하이퍼파라미터 수정전 test정확도 Overfitting 발생한 모습이다.

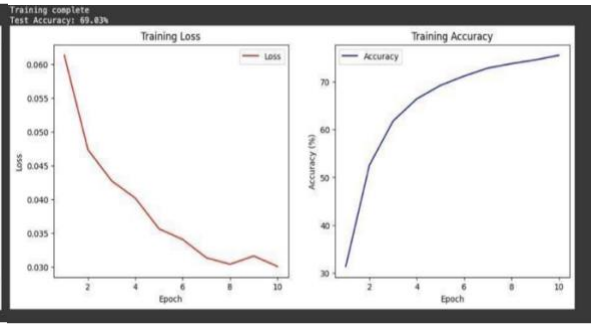

Conv3 Layer추가, FC확장, ReLU >LeakyReLU 적용후 정확도 7%p 상승했다.

정확도 향상을 위해 LeakyReLU->ELU로 활성화 함수 변경을 시도하였다. 그러나 ELU 사용시 오히려 2%p 정확도 감소가 발생하여 다시 LeakyReLU로 회귀하였다.

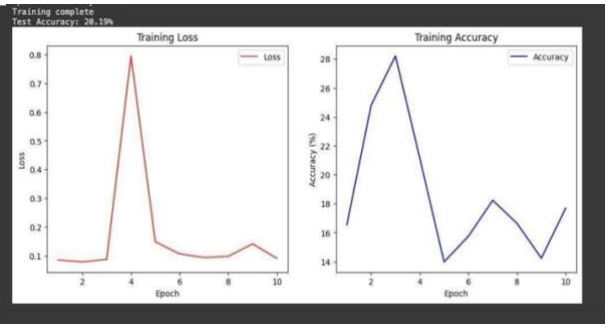

Optimizer SGD->Adam 적용후 심각한 Underfitting(학습률0.01)이 관찰되었다. 최적화 문제일 수 있으므로 회귀가 아닌 학습률을 먼저 조정 예정이다.

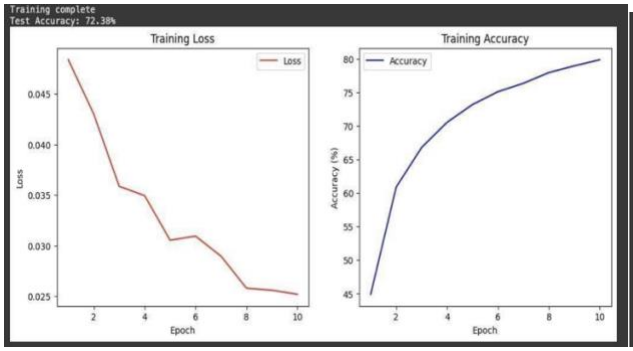

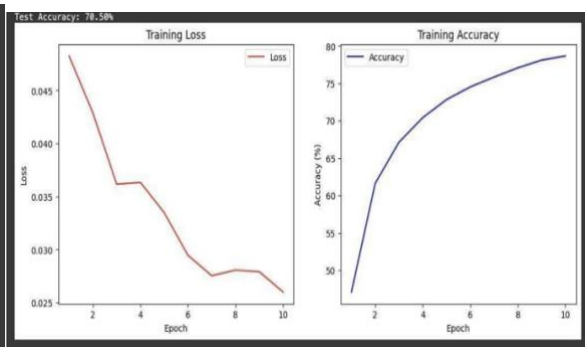

학습률을 0.01에서 0.001로 낮추어 Training을 해보니 Loss 안정화 및 정확도 50%p 개선을 이끌었다. Underfitting의 원인을 높은 학습률로 인한 불안정한 가중치 업데이트로 판단했다.

Adam -> RMSprop로 변경후 2%p 하락이 된 걸 확인하고 다시 Adam으로 회귀하였다.

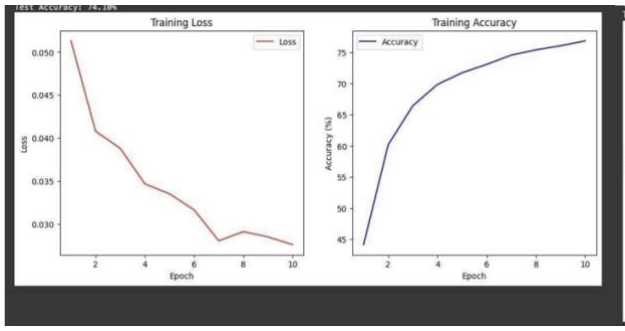

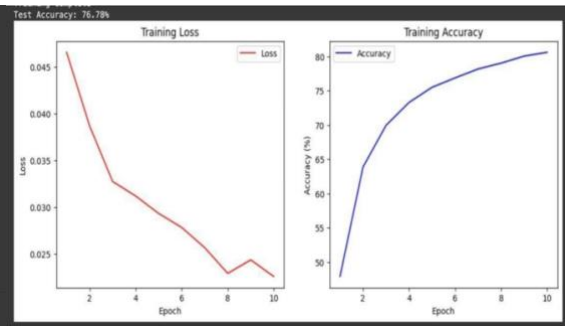

초기 코드에 RandomCrop이 데이터셋에 긍정적인지 확인하고싶어 데이터 증강 기법을 HorizontalFlip 적용 해보았다. 이는 원본 이미지의 주요 정보 손실을 줄이면서도 데이터 다양성을 확보해 테스트 정확도 향상을 기여했다.

모델의 Overfitting방지를 위해 Dropout 비율을 0.3 0.5 0.7로 조정하여 학습하였다. 일반적으로 Dropout은 0.5가 가장 안정적인 설으로 알려져 있지만, 본 프로젝트에선 예상과 다르게 0.3에서 가장 높은 정확도를 기록했다.

2.2 ResNet

이번 프로젝트에서는 기본적으로 제공된 SimpleResNet 구조를 처음에 사용하였는데, 구조의 성능이 하이퍼파라미터 최적화된 CNN보다 낮았기 때문에, 전체 모델 구조를 크게 변경하지 않는 범위 내에서 ResNet의 표현력을 강화하는 방향으로 조정하였다.

```
# 32x32 → 채널 32, 블록 2개
self.layer1 = self._make_layer(32, 32, blocks=2, stride=1)
# 16x16
self.layer2 = self._make_layer(32, 64, blocks=2, stride=2)
# 64x64
self.layer3 = self._make_layer(64, 128, blocks=2, stride=2)
```

우선, 원래 모델은 모든 합성곱 레이어가 동일한 채널 수(16)로 구성되어 있었는데, 이는 CIFAR-10과 같이 클래스 간 시각적 다양성이 큰 데이터셋을 충분히 표현하기에는 한계가 있었다. 이를 개선하기 위해 ResNet의 일반적인 설계 방식에 맞추어 채널을 단계적으로 확장하도록 구조를 수정하였다. 구체적으로는 32 → 64 → 128 채널로 점진적으로 증가시키며, 각 단계마다 residual block을 쌓아 더 풍부한 특징을 학습할 수 있도록 하였다.

이때 채널을 32→64→128로 확장하면서 입력과 출력 텐서의 크기가 달라져 덧셈 연산이 불가능해지는 문제가 발생하였다. 특히 stride=2가 적용되는 지점에서는 공간 크기까지 변해 shape mismatch가 반복적으로 발생했다. 이를 해결하기 위해 skip connection에 1×1 convolution을 사용하는 projection shortcut을 적용하여 채널 수와 공간 크기를 main branch와 일치시키는 구조를 설계하였다. 이 과정에서 residual block은 단순한 identity mapping이 아니라 상황에 따라 학습 가능한 변환을 수행해야 한다는 ResNet의 원리를 실제 코드 구현을 통해 이해할 수 있었다.

```
self.shortcut = nn.Sequential()
if stride != 1 or in_channels != out_channels:
    self.shortcut = nn.Sequential(
        nn.Conv2d(in_channels, out_channels,
                  kernel_size=1, stride=stride, bias=False),
        nn.BatchNorm2d(out_channels)
    )
```

또한 기존 ResBlock은 동일 크기의 feature map을 다루는 형태였으나, 두 번째와 세 번째 계층에서는 stride=2를 사용한 downsampling을 적용하여 공간적 차원을 줄이고 더 추상적인 특징이 학습되도록 하였다. 이 과정에서 공간 크기가 변하면 skip connection이 맞지 않는 문제가 발생하기 때문에 1×1 convolution 기반의 projection shortcut을 사용하여 두 경로의 차원을 맞춰 주었다. 이러한 구조 조정은 단순히 차원을 맞추는데서 그치는 것이 아니라, 깊어지는 계층 간 정보 흐름을 방해하지 않도록 전체 네트워크의 연결 안정성을 높여준다는 점에서 성능 향상에 직접적으로 기여하였다.

downsampling 단계에서 main branch만 stride를 적용할 경우 skip branch와 텐서 크기가 불일치하여 오류가 발생하였고, 이를 방지하기 위해 downsample 모듈을 residual block 안에 포함시키는 구조를 도입하였다. 이를 통해 두 경로가 동일한 크기의 텐서를 출력하도록 조정함으로써 안정적인 add 연산이 가능해졌다.

```
self.conv1 = nn.Conv2d(in_channels, out_channels,
                       kernel_size=3, stride=stride, padding=1, bias=False)
self.bn1 = nn.BatchNorm2d(out_channels)
self.relu = nn.ReLU(inplace=True)

self.conv2 = nn.Conv2d(out_channels, out_channels,
                       kernel_size=3, stride=1, padding=1, bias=False)
self.bn2 = nn.BatchNorm2d(out_channels)
```

마지막으로 모든 convolution 층 뒤에는 Batch Normalization을 적용하여 학습 과정의 분포 변화를 완화하고, ReLU 활성화 함수와 결합하여 gradient 흐름을 더 안정적으로 만들었다. 이는 초기 학습 단계에서 나타나는 불안정성을 줄였으며, 특히 epoch가 증가할수록 손실 감소 속도가 안정적으로 유지되는 효과가 있었다.

초기 구현에서는 Batch Normalization과 ReLU의 순서를 잘못 배치했었다. 이로 인해 loss 폭주와 gradient 불안정 현상이 나타났다. Conv → BN → ReLU 순서로 정렬한 이후 학습이 안정적으로 진행되었다. 이를 통해 BN과 활성화 함수의 배치가 모델 안정성에 매우 중요한 요소임을 확인할 수 있었다.

이와 같은 변경은 전체 네트워크의 흐름을 유지하면서도 표현력과 학습 안정성을 높이는 방향으로 이루어졌고, 최종적으로 test accuracy가 80% 이상으로 상승하는데 기여하였다. 전반적으로 이번 구조 개선 과정은 단순한 코드 수정이 아니라 ResNet의 설계 원리를 실험적으로 이해하는 과정이었으며, skip connection과 downsampling, normalization 구조가 서로 긴밀하게 연결되어 있다는 점을 깨닫는 경험이었다. 이러한 구현 경험은 향후 더 복잡한 신경망을 설계할 때 중요한 기반이 될 것이다.

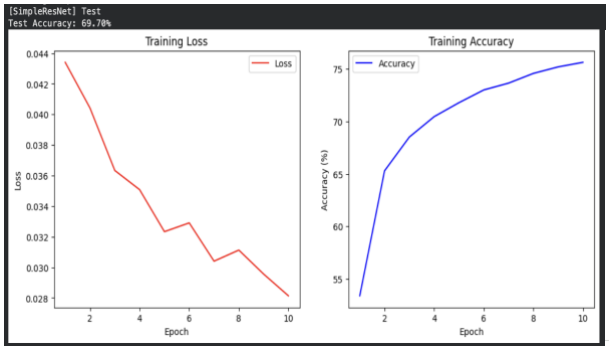

ResNet 재구조화 전 정확도 69.7%

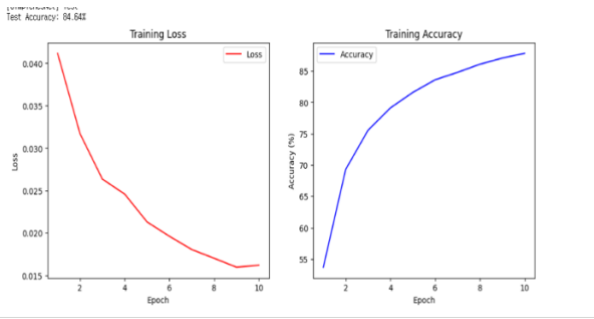

구조화 후 정확도 84.64%

3.결론

본 프로젝트는 CIFAR-10 데이터셋을 기반으로 기본 CNN과 ResNet 모델을 직접 구현하고 구조적 차이가 실제 성능에 어떤 영향을 주는지 실험적으로 분석하는 것을 목표로

하였다. 특히 CNN 대비 ResNet이 갖는 이점, 깊은 네트워크에서의 학습 안정성, 기울기 보존, 표현력 증가를 확인하고자 하였으며, 다양한 하이퍼파라미터 조정을 병행하여 두 모델의 성능을 비교하였다.

초기 CNN 모델은 3 개의 Convolution Layer 와 1 개의 Fully Connected Layer 로 구성된 단순 구조로 기본 성능은 약 60% 중반대였다. 이후 채널 확장, 활성화 함수 변경(LeakyReLU, ELU), Dropout 조정, 학습률 튜닝 및 RandomHorizontalFlip 등을 적용하며 성능은 최대 84.64%까지 향상되었다.

그러나 CNN 기반 구조는 깊이를 늘릴수록 성능이 증가하지 않는 문제를 보였다. 특히 layer 를 추가하거나 channel 수를 무작정 늘렸을 때 오히려 학습이 불안정해지고 과적합 혹은 성능 하락이 발생하였다. 이런 문제점에 중점을 두어 ResNet 구조를 구현하였으며, 그 과정에서 다음과 같은 4 가지 핵심 요소를 모델 설계에 반영했다.

(1) Residual(잔차) Block 구현
(2) F(x) + x 형태의 skip connection, Projection Shortcut 추가
(3) 채널 수나 feature 크기가 달라지는 경우 1×1 conv 로 맞춰주는 구조네트워크 깊이 확장 (32 → 64 → 128 채널), 각 Block 마다 BatchNorm + ReLU 적용
(4) Downsampling 이 필요한 Block 은 stride=2 사용

CNN 구조는 layer 순차 연결로만 이루어져 있어 네트워크가 깊어질수록 기울기 소실 문제가 발생했다. 본 탐구에서도 CNN 의 크기를 늘릴수록 초기 로스값 감소, 학습 후반부 수렴 불안정, 일정 깊이 이후 정확도 정체와 같은 문제가 나타났다.

반면, ResNet 은 skip connection 을 사용함으로써 기울기 흐름을 안정적으로 만들어주며 깊은 네트워크에서도 학습이 안정적으로 이루어졌다. 이것은 "Deep Residual Learning for Image Recognition(2016)"의 CIFAR-10 실험에서 '전통적 CNN 의 정확도는 깊어질수록 감소하나, ResNet 은 깊이가 늘어날수록 오히려 성능 증가하며, Residual block 이 gradient 흐름을 개선한 것이 핵심적으로 기여한다'는 내용과 실제 본 프로젝트의 탐구 결과가 정확히 일치함을 보여준다.[6]

본 프로젝트는 CNN 과 ResNet 을 동일한 실험 조건에서 비교함으로써 Residual Learning 이 깊은 신경망 학습을 성공적으로 가능하게 한다는 사실을 검증하였다. CNN 은 구조 변경과 하이퍼파라미터 조정을 통해 성능을 상당히 개선할 수 있었지만, 여전히 깊이 증가 시 성능 저하와 학습 불안정성을 보이는 구조적 한계를 가지고 있었다. 반면 ResNet 은 skip connection 을 통해 gradient 소실 문제를 해결함으로써, 상대적으로 깊은 구조임에도 CNN 을 안정적으로 능가하는 성능을 보였다.

또한 재구조화된 ResNet 은 논문과 동일한 동작 원리를 따랐고, 실제 성능 향상 효과 또한 논문 결과와 일치하였다.

최종적으로 본 프로젝트를 통해 ResNet 의 설계가 단순한 layer 추가가 아니라 딥러닝 모델 최적화 문제를 해결하는 혁신적인 구조임을 확인하였다. 이는 향후 더 깊은 모델로 확장할 때 성능 향상이 더욱 뚜렷하게 나타날 것이라는 가능성을 제시한다.

참고문헌

[1] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444.
[2] 박성준, 김진성. (2019). "딥러닝 기반의 스마트 팩토리 불량 검출 시스템 설계." *한국정보통신학회논문지*, 23(5), 585-592.

[3] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *In Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)* (pp. 770-778).

[4] 송재민 외. (2020). "이미지 인식 기술의 산업 적용 동향 연구". *한국콘텐츠학회논문지*, 20(7), 86-96. (CNN 발전 흐름 및 산업 동향 관련)

[5] 신준호 외. (2024). "CIFAR-10 데이터셋을 활용한 합성곱 신경망 기반 이미지 분류 성능 평가". *한국정보처리학회 학술대회논문집*. (CIFAR-10 데이터셋 활용 및 실험 설계 관련)

[6] Kaiming He(1저자) 외 4명 “Deep Residual Learning for Image Recognition”